

第五章 共轭梯度法

杜磊

dulei@dlut.edu.cn

大连理工大学 数学科学学院
创新园大厦 B1207

2019 年 10 月 22 日

内容提要

- 1 最速下降法
- 2 共轭梯度法及其基本性质
- 3 实用共轭梯度法及其收敛性
- 4 预优共轭梯度法
- 5 Krylov 子空间法

最速下降法

定理

设 A 对称正定, 求方程组 $Ax = b$ 的解等价于求二次泛函 $\phi(x) = x^T Ax - 2b^T x$ 的极小值点.

最速下降法

定理

设 A 对称正定, 求方程组 $Ax = b$ 的解等价于求二次泛函 $\phi(x) = x^T Ax - 2b^T x$ 的极小值点.

Algorithm 2 最速下降法

- 1: 设定初始向量 x_0 ;
- 2: $r_0 = b - Ax_0$, $k = 0$;
- 3: **while** $r_k \neq 0$ **do**
- 4: $k = k + 1$;
- 5: $\alpha_{k-1} = \frac{r_{k-1}^T r_{k-1}}{r_{k-1}^T A r_{k-1}}$;
- 6: $x_k = x_{k-1} + \alpha_{k-1} r_{k-1}$;
- 7: $r_k = b - Ax_k$; ($r_k = r_{k-1} - \alpha_{k-1} A r_{k-1}$)
- 8: **end while**

最速下降法

定理

设 A 的特征值为 $0 < \lambda_1 \leq \cdots \leq \lambda_n$, 则由最速下降法产生的序列 $\{x_k\}$ 满足

$$\|x_k - x_*\|_A \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^k \|x_0 - x_*\|_A,$$

其中 $x_* = A^{-1}b$, $\|x\|_A = \sqrt{x^T A x}$.

最速下降法

定理

设 A 的特征值为 $0 < \lambda_1 \leq \cdots \leq \lambda_n$, 则由最速下降法产生的序列 $\{x_k\}$ 满足

$$\|x_k - x_*\|_A \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^k \|x_0 - x_*\|_A,$$

其中 $x_* = A^{-1}b$, $\|x\|_A = \sqrt{x^T A x}$.

引理

设 A 的特征值为 $0 < \lambda_1 \leq \cdots \leq \lambda_n$, $P(t)$ 是一个 t 的多项式, 则

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \|x\|_A, \quad x \in \mathbb{R}^n.$$

Chebyshev 多项式及其性质

当权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$, 区间为 $[-1, 1]$ 时, 由序列 $\{1, x, \dots, x^n, \dots\}$ 正交化得到的正交多项式为 Chebyshev 多项式, 表示为

$$T_n(x) = \cos(n \arccos x), \quad |x| \leq 1.$$

Chebyshev 多项式及其性质

当权函数 $\rho(x) = \frac{1}{\sqrt{1-x^2}}$, 区间为 $[-1, 1]$ 时, 由序列 $\{1, x, \dots, x^n, \dots\}$ 正交化得到的正交多项式为 Chebyshev 多项式, 表示为

$$T_n(x) = \cos(n \arccos x), \quad |x| \leq 1.$$

Chebyshev 多项式性质:

- $T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x)$, $n = 1, 2, \dots$, $T_0(x) = 1$, $T_1(x) = x$.
- $\int_{-1}^1 \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \begin{cases} 0, n \neq m; \\ \frac{\pi}{2}, n = m \neq 0; \\ \pi, n = m = 0. \end{cases}$
- $T_{2k}(x)$ 只含 x 的偶次幂; $T_{2k+1}(x)$ 只含 x 的奇次幂;
- $T_n(x)$ 在区间 $[-1, 1]$ 上有 n 个零点 $x_k = \cos \frac{2k-1}{2n} \pi$;

Chebyshev 多项式及其性质

若考虑 $|x| \geq 1$ 情况, Chebyshev 多项式可表示为

$$T_n(x) = \frac{(x + \sqrt{x^2 - 1})^n + (x - \sqrt{x^2 - 1})^n}{2}.$$

Chebyshev 多项式及其性质

若考虑 $|x| \geq 1$ 情况, Chebyshev 多项式可表示为

$$T_n(x) = \frac{(x + \sqrt{x^2 - 1})^n + (x - \sqrt{x^2 - 1})^n}{2}.$$

定理

设 $a, b, c \in \mathbb{R}$ 满足 $a < b$ 且 $|c| \notin [a, b]$, 则下面的最小最大问题

$$\min_{p(\lambda) \in \mathbb{P}_k, p(c)=1} \max_{a \leq \lambda \leq b} |p(\lambda)|$$

的唯一解为

$$\tilde{P}_k(\lambda) = \frac{T_k\left(\frac{b+a-2\lambda}{b-a}\right)}{T_k\left(\frac{b+a-2c}{b-a}\right)}.$$

内容提要

- 1 最速下降法
- 2 共轭梯度法及其基本性质
- 3 实用共轭梯度法及其收敛性
- 4 预优共轭梯度法
- 5 Krylov 子空间法

共轭梯度法

给定初始向量 x_0 , 第一步仍选负梯度方向 $p_0 = r_0$. 以后各步不在选取负梯度方向 r_k , 而是在过点 x_k 由向量 r_k 和 p_{k-1} 所张成的二维平面

$$\pi_2 = \{x = x_k + \xi r_k + \eta p_{k-1} : \xi, \eta \in \mathbb{R}\}$$

内找出使函数 ϕ 下降最快的方向作为新的下山方向 p_k , 即

$$\begin{aligned}\psi(\xi, \eta) &= \phi(x_k + \xi r_k + \eta p_{k-1}) \\ &= (x_k + \xi r_k + \eta p_{k-1})^T A(x_k + \xi r_k + \eta p_{k-1}) \\ &\quad - 2b^T(x_k + \xi r_k + \eta p_{k-1}).\end{aligned}$$

分别对 ξ, η 求偏导可得

$$\begin{aligned}\frac{\partial \psi}{\partial \xi} &= 2(\xi r_k^T A r_k + \eta r_k^T A p_{k-1} - r_k^T r_k) \\ \frac{\partial \psi}{\partial \eta} &= 2(\xi r_k^T A p_{k-1} + \eta p_{k-1}^T A p_{k-1} - \textcolor{red}{r}_k^T \textcolor{red}{p}_{k-1})\end{aligned}$$

共轭梯度法

Algorithm 3 共轭梯度法

```
1: 设定初始向量  $x_0$ ;  
2:  $r_0 = b - Ax_0$ ,  $k = 0$ ;  
3: while  $r_k \neq 0$  do  
4:    $\alpha_k = \frac{r_k^T p_k}{p_k^T A p_k}$ ;  
5:    $x_{k+1} = x_k + \alpha_k p_k$ ;  
6:    $r_{k+1} = b - Ax_{k+1}$ ;  
7:    $\beta_k = -\frac{r_{k+1}^T A p_k}{p_k^T A p_k}$ ;  
8:    $p_{k+1} = r_{k+1} + \beta_k p_k$ ;  
9:    $k = k + 1$ ;  
10: end while
```

共轭梯度法

Algorithm 4 共轭梯度法

- 1: 设定初始向量 x_0 ;
 - 2: $r_0 = b - Ax_0$, $k = 0$; $p_0 = r_0$;
 - 3: **while** $r_k \neq 0$ **do**
 - 4: $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$;
 - 5: $x_{k+1} = x_k + \alpha_k p_k$;
 - 6: $r_{k+1} = r_k - \alpha_k A p_k$
 - 7: $\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$;
 - 8: $p_{k+1} = r_{k+1} + \beta_k p_k$;
 - 9: $k = k + 1$;
 - 10: **end while**
-

基本性质

定理

由共轭梯度法得到的向量组 $\{r_i\}$ 和 $\{p_i\}$ 具有下面的性质:

- ① $p_i^T r_j = 0, 0 \leq i < j \leq k;$
- ② $r_i^T r_j = 0, i \neq j, 0 \leq i, j \leq k;$
- ③ $p_i^T A p_j = 0, i \neq j, 0 \leq i, j \leq k;$
- ④ $\text{span}\{r_0, \dots, r_k\} = \text{span}\{p_0, \dots, p_k\} = \mathcal{K}(A, r_0, k+1)$, 其中 $\mathcal{K}(A, r_0, k+1) = \text{span}\{r_0, A r_0, \dots, A^k r_0\}$, 通常称之为Krylov子空间.

基本性质

定理

由共轭梯度法得到的向量组 $\{r_i\}$ 和 $\{p_i\}$ 具有下面的性质:

- ① $p_i^T r_j = 0, 0 \leq i < j \leq k;$
- ② $r_i^T r_j = 0, i \neq j, 0 \leq i, j \leq k;$
- ③ $p_i^T A p_j = 0, i \neq j, 0 \leq i, j \leq k;$
- ④ $\text{span}\{r_0, \dots, r_k\} = \text{span}\{p_0, \dots, p_k\} = \mathcal{K}(A, r_0, k+1)$, 其中 $\mathcal{K}(A, r_0, k+1) = \text{span}\{r_0, A r_0, \dots, A^k r_0\}$, 通常称之为Krylov子空间.

定理

用共轭梯度法计算得到的近似解 x_k 满足

$$\phi(x_k) = \min\{\phi(x) : x \in x_0 + \mathcal{K}(A, r_0, k)\}$$

或

$$\|x_k - x_*\|_A = \min\{\|x - x_*\|_A : x \in x_0 + \mathcal{K}(A, r_0, k)\},$$

其中 $\|x\|_A = \sqrt{x^T A x}$, $A x_* = b$, $\mathcal{K}(A, r_0, k) = \text{span}\{r_0, A r_0, \dots, A^k r_0\}$.

内容提要

- 1 最速下降法
- 2 共轭梯度法及其基本性质
- 3 实用共轭梯度法及其收敛性**
- 4 预优共轭梯度法
- 5 Krylov 子空间法

实用共轭梯度法

Algorithm 5 实用共轭梯度法

```
1: 设定初始向量  $x$ ;  
2:  $r = b - Ax$ ,  $k = 0$ ;  $\rho = r^T r$ ;  
3: while  $\sqrt{\rho} > \epsilon \|b\|_2$  and  $k < k_{\max}$  do  
4:    $k = k + 1$ ;  
5:   if  $k=1$  then  
6:      $p = r$ ;  
7:   else  
8:      $\beta = \rho / \tilde{\rho}$ ;  $p = r + \beta p$ ;  
9:   end if  
10:   $w = Ap$ ;  $\alpha = \rho / p^T w$ ;  $x = x + \alpha p$ ;  
11:   $r = r - \alpha w$ ;  $\tilde{\rho} = \rho$ ;  $\rho = r^T r$ ;  
12: end while
```

收敛性分析

定理

如果 $A = I + B$, 而且 $\text{rank}(B) = r$, 则共轭梯度法至多迭代 $r + 1$ 步即可得到方程组 $Ax = b$ 的精确解.

收敛性分析

定理

如果 $A = I + B$, 而且 $\text{rank}(B) = r$, 则共轭梯度法至多迭代 $r + 1$ 步即可得到方程组 $Ax = b$ 的精确解.

定理

用共轭梯度法求得的 x_k 有如下的误差估计:

$$\|x_k - x_*\|_A \leq 2 \left(\frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x_0 - x_*\|_A,$$

其中 $\kappa_2 = \kappa_2(A) = \|A\|_2 \|A^{-1}\|_2$.

内容提要

- 1 最速下降法
- 2 共轭梯度法及其基本性质
- 3 实用共轭梯度法及其收敛性
- 4 预优共轭梯度法**
- 5 Krylov 子空间法

预优共轭梯度法 (PCG)

设 L 非奇异, $L^{-1}AL^{-T}L^Tx = L^{-1}b$, 记 $M = LL^T$.

Algorithm 6 共轭梯度法

- 1: 设定初始向量 x_0 ;
- 2: $r_0 = b - Ax_0$, $k = 0$; $p_0 = r_0$;
- 3: **while** $r_k \neq 0$ **do**
- 4: $\alpha_k = \frac{r_k^T r_k}{p_k^T A p_k}$;
- 5: $x_{k+1} = x_k + \alpha_k p_k$;
- 6: $r_{k+1} = r_k - \alpha_k A p_k$
- 7: $\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$;
- 8: $p_{k+1} = r_{k+1} + \beta_k p_k$;
- 9: $k = k + 1$;
- 10: **end while**

Algorithm 7 预优共轭梯度法

- 1: 设定初始向量 x_0 ;
- 2: $r_0 = b - Ax_0$, $k = 0$; $p_0 = r_0$;
- 3: **while** $r_k \neq 0$ **do**
- 4: $\tilde{\alpha}_k = \frac{r_k^T M^{-1} r_k}{p_k^T A p_k}$;
- 5: $x_{k+1} = x_k + \tilde{\alpha}_k p_k$;
- 6: $r_{k+1} = r_k - \tilde{\alpha}_k A p_k$
- 7: $\tilde{\beta}_k = \frac{r_{k+1}^T M^{-1} r_{k+1}}{r_k^T M^{-1} r_k}$;
- 8: $p_{k+1} = M^{-1} r_{k+1} + \tilde{\beta}_k p_k$;
- 9: $k = k + 1$;
- 10: **end while**

预优矩阵 M 选取

- 基本准则:
 - M 是对称正定的;
 - M 是稀疏的;
 - $\lambda(M^{-1}A)$ 分布集中;
 - 方程组 $Mz = r$ 易于求解.
- 常用预优矩阵:
 - 对角矩阵;
 - 不完全 Cholesky 因子分解;
 - 多项式预优矩阵;
 -

内容提要

- 1 最速下降法
- 2 共轭梯度法及其基本性质
- 3 实用共轭梯度法及其收敛性
- 4 预优共轭梯度法
- 5 Krylov 子空间法

定义

设 $A \in \mathbb{R}^{n \times n}$, $r \in \mathbb{R}^n$, 则由 A 和 r 生成的 m 阶 Krylov 子空间为

$$\mathcal{K}_m(A, r) = \text{span}\{r, Ar, A^2r, \dots, A^{m-1}r\}.$$

构造 Krylov 子空间法的两个关键问题:

- 如何基底基底?
- 如何构造近似解?

Algorithm 8 Arnoldi 过程 (Gram-Schmidt)

```
1: 设定  $v_1 = r / \|r\|_2$ ;  
2: for  $j = 1, 2, \dots, m$  do  
3:   计算  $h_{ij} = (Av_j, v_i), i = 1, 2, \dots, j$ ;  
4:   计算  $w_j = Av_j - \sum_{i=1}^j h_{ij}v_i$ ;  
5:    $h_{j+1,j} = \|w_j\|_2$ ;  
6:   如果  $h_{j+1,j} = 0$ , 循环停止.  
7:    $v_{j+1} = w_j / h_{j+1,j}$ ;  
8: end for
```

Arnoldi 过程

引理

如果程序 (8) 前 m 步没有中断, 则 v_1, v_2, \dots, v_m 为 Krylov 子空间 $\mathcal{K}_m(A, r) = \text{span}\{r, Ar, A^2r, \dots, A^{m-1}r\}$ 的一组标准正交基底.

引理

记 $V_m = [v_1, v_2, \dots, v_m]$,

$$H_m = \begin{bmatrix} h_{11} & h_{12} & h_{13} & \cdots & h_{1m} \\ h_{21} & h_{22} & h_{23} & \cdots & h_{2m} \\ & h_{32} & h_{33} & \cdots & h_{3m} \\ & & \ddots & \ddots & \vdots \\ & & & h_{m-1,m} & h_{mm} \end{bmatrix}, \tilde{H}_m = \begin{bmatrix} H_m \\ h_{m+1,m} \end{bmatrix},$$

则有下列关系成立:

$$AV_m = V_m H_m + h_{m+1,m} v_{m+1} e_m^T = V_{m+1} \tilde{H}_m,$$
$$V_m^T A V_m = H_m.$$

Algorithm 9 Arnoldi 过程 (Modified Gram-Schmidt)

```
1: 设定  $v_1 = r / \|r\|_2$ ;  
2: for  $j = 1, 2, \dots, m$  do  
3:   计算  $w_j = A v_j$ ;  
4:   for  $i = 1, 2, \dots, j$  do  
5:      $h_{ij} = (w_j, v_i)$ ;  
6:      $w_j = w_j - h_{ij} v_i$ ;  
7:   end for  
8:    $h_{j+1,j} = \|w_j\|_2$ ;  
9:   如果  $h_{j+1,j} = 0$ , 循环停止.  
10:   $v_{j+1} = w_j / h_{j+1,j}$ ;  
11: end for
```

Lanczos 过程

如果 A 为对称矩阵, 则 H_m 为对称三对角矩阵

引理

记 $V_m = [v_1, v_2, \dots, v_m]$,

$$H_m = \begin{bmatrix} \alpha_1 & \beta_1 & & \\ \beta_1 & \ddots & \ddots & \\ & \ddots & \ddots & \beta_{m-1} \\ & & \beta_{m-1} & \alpha_m \end{bmatrix}, \tilde{H}_m = \begin{bmatrix} H_m \\ \beta_m \end{bmatrix},$$

则有下列关系成立:

$$\begin{aligned} A V_m &= V_m H_m + \beta_m v_{m+1} e_m^T = V_{m+1} \tilde{H}_m, \\ V_m^T A V_m &= H_m. \end{aligned}$$

Algorithm 10 Lanczos 过程

```
1: 设定  $v_0 = 0, \beta_0 = 0, v_1 = r / \|r\|_2$ ;  
2: for  $j = 1, 2, \dots, m - 1$  do  
3:   计算  $z = Av_j$ ;  
4:    $\alpha_j = v_j^T z$ ;  
5:    $z = z - \alpha_j v_j - \beta_{j-1} v_{j-1}$ ;  
6:    $\beta_j = \|z\|_2$ ;  
7:   如果  $\beta_j = 0$ , 循环停止.  
8:    $v_{j+1} = z / \beta_j$ ;  
9: end for
```

相关文献



D.P. O'Leary

Some History of Conjugate Gradients and Other Krylov Subspace Methods

<https://archive.siam.org/meetings/la09/talks/oleary.pdf>.



G.H. Golub & D.P. O'Leary

Some History of the Conjugate Gradient and Lanczos Algorithms: 1948–1976

SIAM Review, 31:1(1989), 50-102.